ДЗ №4. Обеспечение отказоустойчивости средствами Apache ZooKeeper

Выполнил: Афанасьев Николай Игоревич, группа J3314 (ФТИИ, ИТМО). **Вариант 1: «Программист, разработчик на 1С».** Окружение: MacBook (Apple M4, 10 ядер, 16 ГБ), Docker Desktop, ZooKeeper 3.9.6 (официальный образ, Java 17.0.21), RustFS из ДЗ №3 (бакет hh-lake), Python 3.14, kazoo 2.11. Репозиторий: `github.com/Stalnoy-gigant/de-hw4-zookeeper`.

1. Цель и общая схема

Поднять ансамбль из трёх серверов ZooKeeper, проверить кворум и эфемерные узлы, а затем встроить ZooKeeper в координатор расчёта сочетаний навыков из ДЗ №3: две копии координатора выбирают лидера, лидер сохраняет чекпоинты, при его зависании запасной продолжает с чекпоинта, а устаревший лидер после «пробуждения» не должен перезаписать результат. Последнее обеспечивается проверкой эпохи при публикации (FENCING=1).

2. Этап 1. Установка

Java на машине не установлена, поэтому выбран разрешённый заданием вариант с Docker: три контейнера из образа `zookeeper:3.9.6` (внутри Eclipse Temurin Java 17.0.21). Каждый контейнер играет роль отдельной распакованной копии: у него свой каталог `zk/zkN/` с `conf/zoo.cfg` и `data/myid`, подключённый в контейнер. Сервер запускается штатной командой `zkServer.sh start-foreground` (поле command в compose.yaml). Версии видны в выводе клиента: `zookeeper.version=3.9.6`, `java.version=17.0.21` (рис. 3).

3. Этап 2. Ансамбль из трёх серверов

Строки участников `server.N` одинаковые во всех трёх конфигурациях, а клиентский порт, порты кворума/выборов и dataDir у каждого сервера свои — как если бы три копии работали на одной машине. Файл myid в dataDir сообщает серверу, какая строка server.N относится к нему.

Сервер	myid	clientPort	Порт кворума : выборов	dataDir
zk1	1	2181	2888 : 3888	/var/zookeeper/data1 (← zk/zk1/data)
zk2	2	2182	2889 : 3889	/var/zookeeper/data2 (← zk/zk2/data)
zk3	3	2183	2890 : 3890	/var/zookeeper/data3 (← zk/zk3/data)

Конфигурация zk/zk1/conf/zoo.cfg (у zk2/zk3 отличаются только dataDir и clientPort):

```
# ZooKeeper 3.9.6, сервер 1 из 3
tickTime=2000
initLimit=10
syncLimit=5
# у каждого сервера своя папка данных (в ней лежит myid = 1)
dataDir=/var/zookeeper/data1
# у каждого сервера свой клиентский порт
clientPort=2181
# строки участников ансамбля одинаковые у всех трёх: host:порт_кворума:порт_выборов
server.1=zk1:2888:3888
server.2=zk2:2889:3889
server.3=zk3:2890:3890
4lw.commands.whitelist=srvr,stat,ruok,mntr
admin.enableServer=false
```

Проверки выполнены дважды: вручную (скриншоты ниже) и скриптом stage2.sh (полный текстовый вывод — outputs/stage2.txt). Лидер выбирается при каждом запуске заново, поэтому в ручном прогоне лидером был zk3, а в скриптовом — zk2.

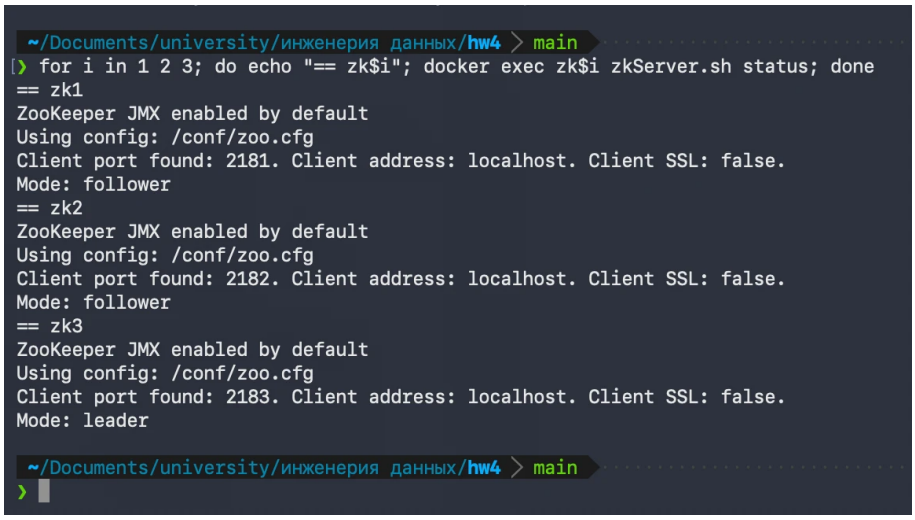


Рис. 1. Роли серверов: zk3 — leader, zk1 и zk2 — follower.

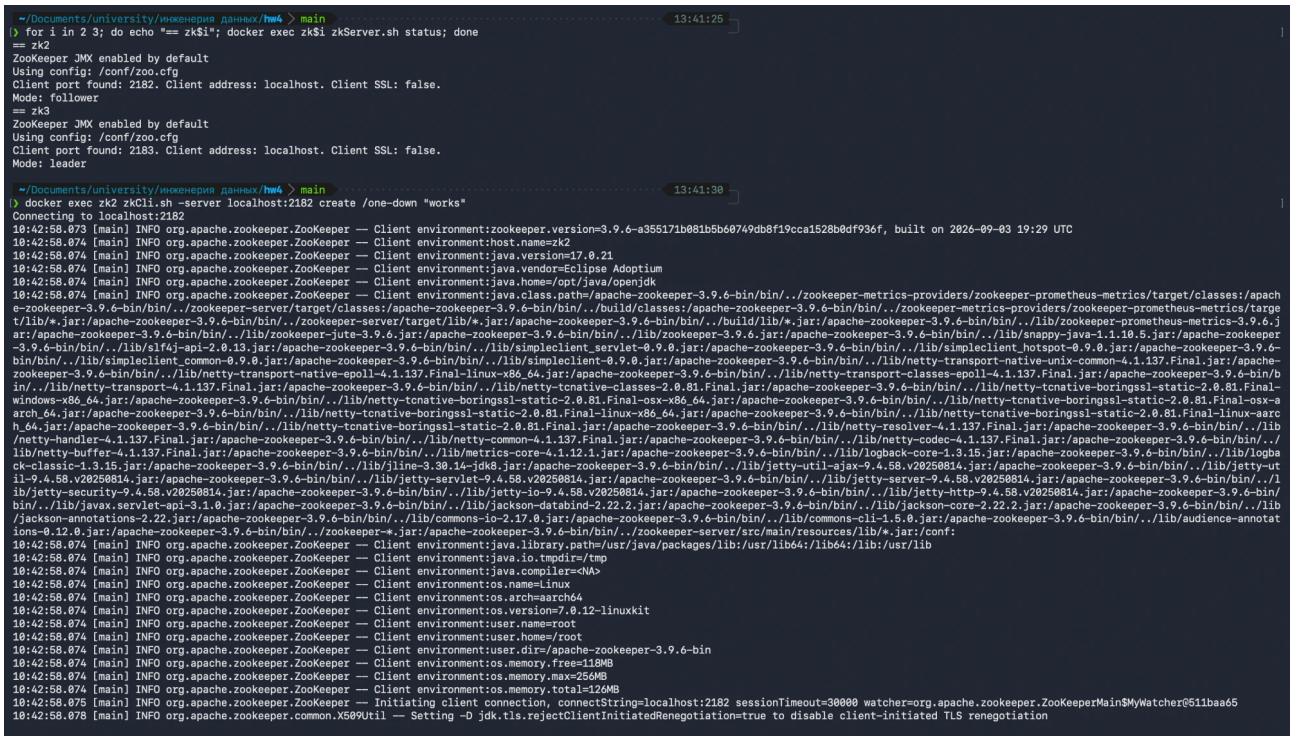


Рис. 2. Остановлен zk1 (docker stop zk1): zk2 — follower, zk3 — leader, ансамбль работает.



Рис. 3. Запись при двух живых серверах из трёх: Created /one-down (версии ZooKeeper и Java видны в начале вывода).

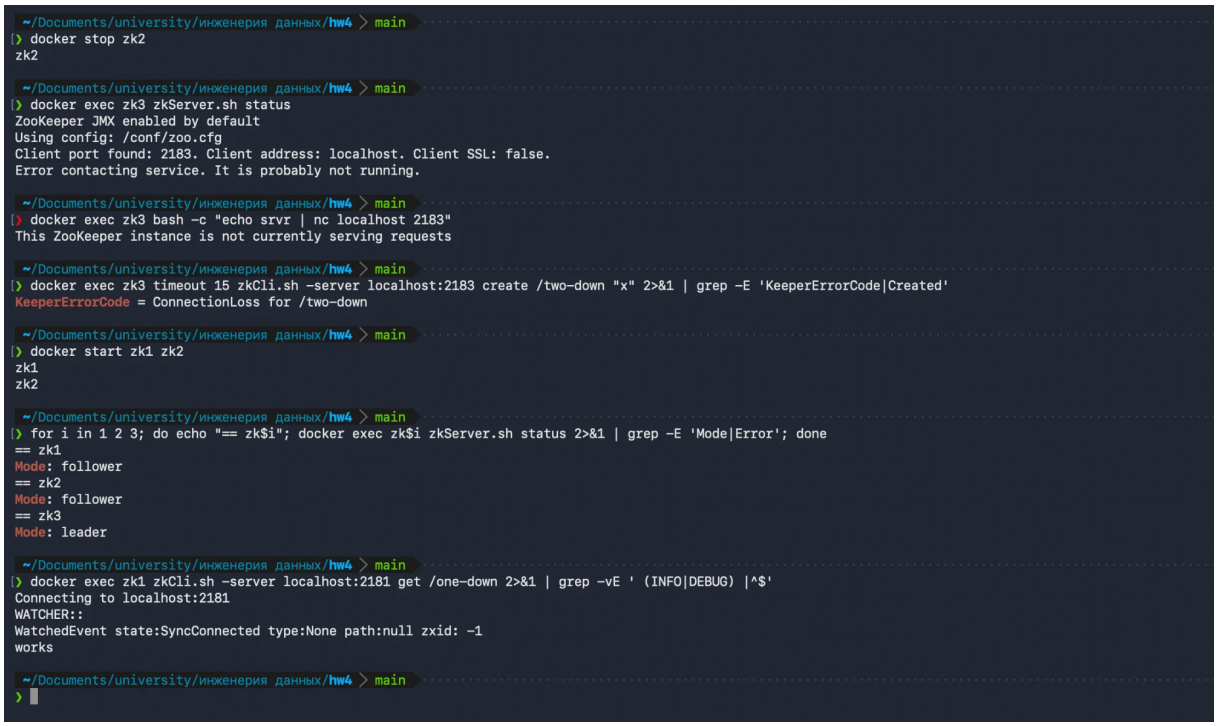


Рис. 4. Остановлен второй сервер: zk3 — «Error contacting service», «This ZooKeeper instance is not currently serving requests», клиент получает ConnectionLoss. После docker start zk1 zk2 роли восстановились, узел /one-down со значением works сохранился.

Процесс на zk3 при этом жив (в скриптовом прогоне `ruok` отвечает `imok`), но без кворума (2 из 3) сервер отказывается обслуживать запросы — он не может знать, не выбрало ли большинство уже другого лидера и не ушли ли данные вперёд.

Эфемерный узел

В окне 2 открыт интерактивный zkCli и создан узел с флагом -e; в окне 1 другой клиент видит его, а после quit в окне 2 (сессия закрыта) узел исчезает. Обычный узел /one-down при этом остаётся.

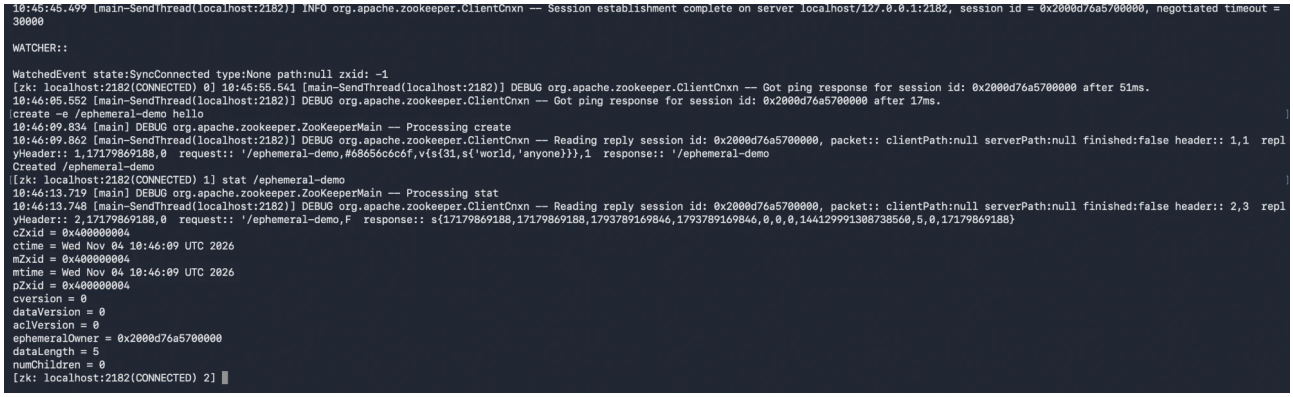


Рис. 5. Окно 2: create -e /ephemeral-demo hello; ephemeralOwner = 0x2000d76a5700000 — id сессии этого клиента.

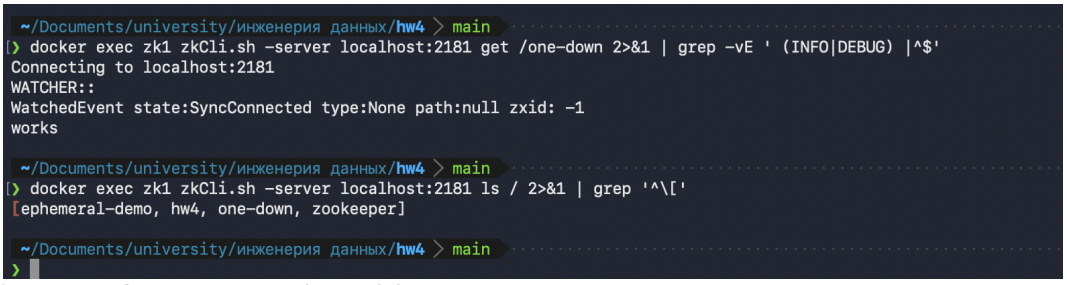


Рис. 6. Окно 1, пока окно 2 открыто: узел ephemeral-demo есть.



Рис. 7. Окно 1 после quit в окне 2: ephemeral-demo пропал, Node does not exist.

4. Координатор расчёта под управлением ZooKeeper

Расчёт тот же, что в ДЗ №3 (src/mr.py): объект `clean/vacancies.jsonl` (100 922 060 байт) читается из RustFS чанками через HTTP Range, фильтр варианта (роль «Программист, разработчик» + 1С в названии или навыках), подсчёт сочетаний навыков размера 1, 2, 3. Чтобы лидера можно было остановить посреди расчёта, чанки уменьшены до 4 МиБ (25 штук), обрабатываются последовательно, и после каждого стоит пауза 1 с. Код — src/coordinator.py, тайм-аут сессии 10 с.

```
/hw4/<run>/
├── election/n_0000000000   эфемерный последовательный узел A  (лидер = наименьший номер)
├── election/n_0000000001   эфемерный узел B, B ставит watch на узел предшественника
├── epoch                   счётчик эпох: новый лидер делает set(epoch, e+1, version=v); версия узла = номер эпохи
├── checkpoint/chunk_NNNN   чанк обработан (данные "A epoch=1"); частичный Counter -> s3://hh-lake/hw4/<run>/partial/
└── result                  указатель на результат (создаётся пустым, version 0); CSV -> s3://hh-lake/hw4/<run>/result_*
```

• **Выбор лидера.** Каждая копия создаёт эфемерный последовательный узел в election/. Владелец наименьшего номера — лидер; остальные следят только за предшественником (без «стада», когда все ждут одного узла). Когда сессия лидера истекает, ZooKeeper удаляет его эфемерный узел, и запасной получает уведомление.

• **Эпоха.** Став лидером, координатор увеличивает /epoch условной записью и запоминает версию узла — это его номер эпохи.

• **Чекпоинт.** После каждого чанка частичный результат пишется в S3, затем создаётся узел checkpoint/chunk_NNNN. Новый лидер пропускает чанки, для которых узел уже есть, а в reduce берёт частичные результаты всех 25 чанков.

• **Публикация.** Без защиты — `set(result)` без условий. С FENCING=1 — транзакция `check(epoch, version=моя_эпоха) + set_data(result)`: если эпоха сменилась, вся транзакция отклоняется с BadVersionError и указатель не меняется.

• **Сценарий** (src/scenario.py) запускает A, затем B, после 8-го чанка делает `kill -STOP` лидеру A, ждёт, пока B опубликует результат, держит A на паузе 40 с и делает `kill -CONT`. Время смены лидера = момент «СТАЛ ЛИДЕРОМ» в журнале B минус момент SIGSTOP.

5. Этап 3. Приостановка лидера без защиты (FENCING=0)

t, с	Событие
9.40	kill -STOP: лидер A приостановлен после 8 обработанных чанков
21.03	B стал лидером, эпоха 2 (через **11.63 с** после SIGSTOP)
21.03	B: 8 чанков уже в чекпоинте A — пропущены, расчёт продолжен с чанка 9
47.38	B: записал результат: /hw4/nofence/result -> версия 1 (без проверки эпохи)
49.41	kill -CONT: A возобновлён (пауза 40.0 с); сессия A истекла (LOST), переподключение
51.92	A: все 17 оставшихся чанков в чекпоинте; записал результат: /hw4/nofence/result -> версия 2 (без проверки эпохи)

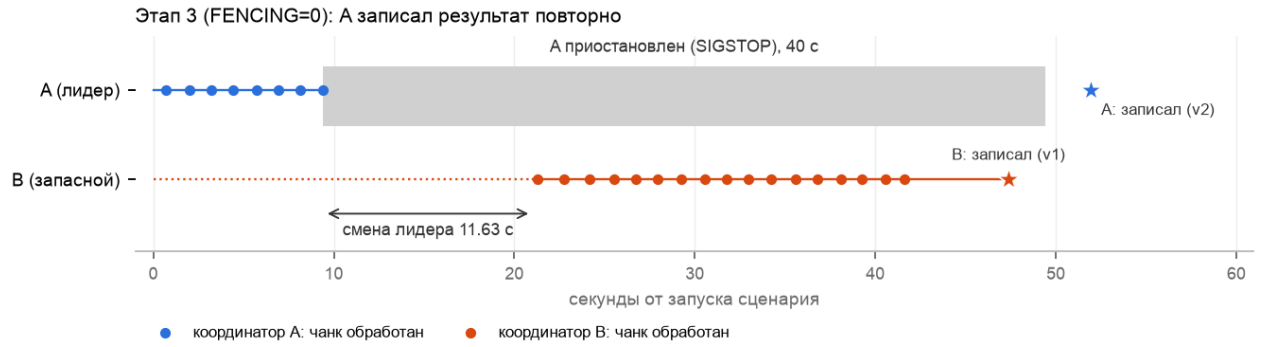


Рис. 8. Хронология прогона nofence по журналам logs/nofence_A.log и logs/nofence_B.log.

Запасной B продолжил с чекпоинта, а возобновивший работу A не знает, что он уже не лидер: досчитал reduce и, не проверяя эпоху, перезаписал указатель. В итоге две строки «записал результат», указатель `/hw4/nofence/result` имеет **dataVersion = 2** и owner = A, epoch = 1 — актуальный результат B затёрт результатом устаревшего лидера. Здесь данные одинаковые, поэтому вреда нет, но в общем случае старый лидер мог бы записать устаревшие данные.

```
❯ tail -F logs/nofence_B.log
2026-11-04 13:22:55.084 [B] чанк 23/25 обработан: lines=9279 variant=1169 -> чекпоинт chunk_0022 (0.26s)  (t=1793787775.085)
2026-11-04 13:22:56.314 [B] чанк 24/25 обработан: lines=9204 variant=1140 -> чекпоинт chunk_0023 (0.22s)  (t=1793787776.314)
2026-11-04 13:22:57.406 [B] чанк 25/25 обработан: lines=567 variant=57 -> чекпоинт chunk_0024 (0.08s)  (t=1793787777.406)
2026-11-04 13:22:59.666 [B] reduce завершён: lines=229,388 variant_vacancies=23,627  (t=1793787779.667)
2026-11-04 13:22:59.690 [B] k=1: distinct=3,112 total_occurrences=94,278 top=[('1с программирование', 10432), ('1с: предприятие 8', 5583), ('1с: бухгалтерия', 3633)] | сверка с results/mr_k1.csv: СОВПАЛО с Д
3 3  (t=1793787779.690)
2026-11-04 13:22:59.808 [B] k=2: distinct=48,616 total_occurrences=353,186 top=[('1с программирование | 1с: предприятие 8', 4465), ('1с программирование | 1с: бухгалтерия', 2824), ('1с программирование | обн
овление конфигурации 1с', 2430)] | сверка с results/mr_k2.csv: СОВПАЛО с ДЗ 3  (t=1793787779.808)
2026-11-04 13:23:01.809 [B] k=3: distinct=338,381 total_occurrences=1,204,741 top=[('1с программирование | 1с: бухгалтерия | 1с: предприятие 8', 1597), ('1с программирование | 1с: предприятие 8 | 1с: управле
ние торговлей', 1370), ('1с программирование | 1с: предприятие 8 | обновление конфигурации 1с', 1364)] | сверка с results/mr_k3.csv: СОВПАЛО с ДЗ 3  (t=1793787781.809)
2026-11-04 13:23:01.852 [B] записал результат: /hw4/nofence/result -> версия 1 (без проверки эпохи)  (t=1793787781.852)
2026-11-04 13:23:01.854 [B] указатель /hw4/nofence/result: version=1 owner=B  (t=1793787781.854)
2026-11-04 13:23:01.856 [B] сессия закрыта, завершение  (t=1793787781.857)
2026-11-04 13:48:32.306 [B] старт pid=81315 run=nofence FENCING=0 zk=localhost:2181,localhost:2182,localhost:2183  (t=1793789312.306)
2026-11-04 13:48:32.320 [B] подключён к ZooKeeper (CONNECTED)  (t=1793789312.320)
2026-11-04 13:48:32.354 [B] зарегистрировался в выборах: /hw4/nofence/election/n_0000000001, session=0x3000d76a5710000, timeout=10s  (t=1793789312.354)
2026-11-04 13:48:32.366 [B] запасной: лидер A (n_0000000000), жду исчезновения его узла  (t=1793789312.366)
2026-11-04 13:48:52.863 [B] узел n_0000000000 исчез — перевыборы  (t=1793789332.863)
2026-11-04 13:48:52.877 [B] СТАЛ ЛИДЕРОМ, эпоха 2 (версия узла epoch 2), ожидал 20.52s  (t=1793789332.877)
2026-11-04 13:48:52.908 [B] объект clean/vacancies.jsonl: 100,922,060 байт, 25 чанков, в чекпоинте уже 8  (t=1793789332.908)
2026-11-04 13:48:52.913 [B] чанк 1/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.914)
2026-11-04 13:48:52.918 [B] чанк 2/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.919)
2026-11-04 13:48:52.921 [B] чанк 3/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.921)
2026-11-04 13:48:52.923 [B] чанк 4/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.923)
2026-11-04 13:48:52.926 [B] чанк 5/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.926)
2026-11-04 13:48:52.927 [B] чанк 6/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.928)
2026-11-04 13:48:52.929 [B] чанк 7/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.929)
2026-11-04 13:48:52.930 [B] чанк 8/25 уже в чекпоинте (A epoch=1) — пропуск  (t=1793789332.930)
2026-11-04 13:48:53.147 [B] чанк 9/25 обработан: lines=9654 variant=874 -> чекпоинт chunk_0008 (0.22s)  (t=1793789333.148)
2026-11-04 13:48:54.611 [B] чанк 10/25 обработан: lines=9413 variant=1087 -> чекпоинт chunk_0009 (0.45s)  (t=1793789334.611)
2026-11-04 13:48:56.033 [B] чанк 11/25 обработан: lines=9882 variant=653 -> чекпоинт chunk_0010 (0.41s)  (t=1793789336.033)
2026-11-04 13:48:57.374 [B] чанк 12/25 обработан: lines=10159 variant=650 -> чекпоинт chunk_0011 (0.30s)  (t=1793789337.374)
2026-11-04 13:48:58.603 [B] чанк 13/25 обработан: lines=10199 variant=686 -> чекпоинт chunk_0012 (0.22s)  (t=1793789338.604)
2026-11-04 13:48:59.803 [B] чанк 14/25 обработан: lines=10365 variant=622 -> чекпоинт chunk_0013 (0.19s)  (t=1793789339.803)
2026-11-04 13:49:01.105 [B] чанк 15/25 обработан: lines=9220 variant=1184 -> чекпоинт chunk_0014 (0.29s)  (t=1793789341.105)
2026-11-04 13:49:02.383 [B] чанк 16/25 обработан: lines=9189 variant=1132 -> чекпоинт chunk_0015 (0.27s)  (t=1793789342.383)
2026-11-04 13:49:03.602 [B] чанк 17/25 обработан: lines=9238 variant=1165 -> чекпоинт chunk_0016 (0.21s)  (t=1793789343.602)
2026-11-04 13:49:04.822 [B] чанк 18/25 обработан: lines=9211 variant=1277 -> чекпоинт chunk_0017 (0.21s)  (t=1793789344.822)
2026-11-04 13:49:06.098 [B] чанк 19/25 обработан: lines=9230 variant=1216 -> чекпоинт chunk_0018 (0.27s)  (t=1793789346.098)
2026-11-04 13:49:07.421 [B] чанк 20/25 обработан: lines=9541 variant=1022 -> чекпоинт chunk_0019 (0.31s)  (t=1793789347.421)
2026-11-04 13:49:08.646 [B] чанк 21/25 обработан: lines=9385 variant=1179 -> чекпоинт chunk_0020 (0.22s)  (t=1793789348.646)
2026-11-04 13:49:09.927 [B] чанк 22/25 обработан: lines=9429 variant=1059 -> чекпоинт chunk_0021 (0.26s)  (t=1793789349.927)
2026-11-04 13:49:11.128 [B] чанк 23/25 обработан: lines=9279 variant=1169 -> чекпоинт chunk_0022 (0.20s)  (t=1793789351.128)
2026-11-04 13:49:12.407 [B] чанк 24/25 обработан: lines=9204 variant=1140 -> чекпоинт chunk_0023 (0.26s)  (t=1793789352.407)
2026-11-04 13:49:13.470 [B] чанк 25/25 обработан: lines=567 variant=57 -> чекпоинт chunk_0024 (0.06s)  (t=1793789353.470)
2026-11-04 13:49:15.666 [B] reduce завершён: lines=229,388 variant_vacancies=23,627  (t=1793789355.667)
2026-11-04 13:49:15.704 [B] k=1: distinct=3,112 total_occurrences=94,278 top=[('1с программирование', 10432), ('1с: предприятие 8', 5583), ('1с: бухгалтерия', 3633)] | сверка с results/mr_k1.csv: СОВПАЛО с Д
3 3  (t=1793789355.704)
2026-11-04 13:49:15.901 [B] k=2: distinct=48,616 total_occurrences=353,186 top=[('1с программирование | 1с: предприятие 8', 4465), ('1с программирование | 1с: бухгалтерия', 2824), ('1с программирование | обн
овление конфигурации 1с', 2430)] | сверка с results/mr_k2.csv: СОВПАЛО с ДЗ 3  (t=1793789355.901)
2026-11-04 13:49:19.155 [B] k=3: distinct=338,381 total_occurrences=1,204,741 top=[('1с программирование | 1с: бухгалтерия | 1с: предприятие 8', 1597), ('1с программирование | 1с: предприятие 8 | 1с: управле
ние торговлей', 1370), ('1с программирование | 1с: предприятие 8 | обновление конфигурации 1с', 1364)] | сверка с results/mr_k3.csv: СОВПАЛО с ДЗ 3  (t=1793789359.155)
2026-11-04 13:49:19.232 [B] записал результат: /hw4/nofence/result -> версия 1 (без проверки эпохи)  (t=1793789359.232)
2026-11-04 13:49:19.235 [B] указатель /hw4/nofence/result: version=1 owner=B  (t=1793789359.236)
2026-11-04 13:49:19.237 [B] сессия закрыта, завершение  (t=1793789359.238)
```

Рис. 9. Журнал B: ожидание, «СТАЛ ЛИДЕРОМ, эпоха 2», пропуск 8 чанков из чекпоинта A, продолжение с 9-го, СОВПАЛО с ДЗ 3, записал результат (версия 1).

```
Node does not exist: /ephemeral-demo
~/Documents/university/инженерия данных/hw4 > main                                                                    1|0 ✔ < 13:47:05
❯ tail -F logs/nofence_A.log
2026-11-04 13:23:06.469 [A] чанк 23/25 уже в чекпоинте (B epoch=2) — пропуск  (t=1793787786.470)
2026-11-04 13:23:06.471 [A] чанк 24/25 уже в чекпоинте (B epoch=2) — пропуск  (t=1793787786.471)
2026-11-04 13:23:06.472 [A] чанк 25/25 уже в чекпоинте (B epoch=2) — пропуск  (t=1793787786.473)
2026-11-04 13:23:07.608 [A] reduce завершён: lines=229,388 variant_vacancies=23,627  (t=1793787787.608)
2026-11-04 13:23:07.638 [A] k=1: distinct=3,112 total_occurrences=94,278 top=[('1с программирование', 10432), ('1с: предприятие 8', 5583), ('1с: бухгалтерия', 3633)] | сверка с results/mr_k1.csv: СОВПАЛО с Д
3 3  (t=1793787787.639)
2026-11-04 13:23:07.757 [A] k=2: distinct=48,616 total_occurrences=353,186 top=[('1с программирование | 1с: предприятие 8', 4465), ('1с программирование | 1с: бухгалтерия', 2824), ('1с программирование | обн
овление конфигурации 1с', 2430)] | сверка с results/mr_k2.csv: СОВПАЛО с ДЗ 3  (t=1793787787.757)
2026-11-04 13:23:08.629 [A] k=3: distinct=338,381 total_occurrences=1,204,741 top=[('1с программирование | 1с: бухгалтерия | 1с: предприятие 8', 1597), ('1с программирование | 1с: предприятие 8 | 1с: управле
ние торговлей', 1370), ('1с программирование | 1с: предприятие 8 | обновление конфигурации 1с', 1364)] | сверка с results/mr_k3.csv: СОВПАЛО с ДЗ 3  (t=1793787788.630)
2026-11-04 13:23:08.665 [A] записал результат: /hw4/nofence/result -> версия 2 (без проверки эпохи)  (t=1793787788.666)
2026-11-04 13:23:08.667 [A] указатель /hw4/nofence/result: version=2 owner=A  (t=1793787788.668)
2026-11-04 13:23:08.669 [A] сессия закрыта, завершение  (t=1793787788.669)
2026-11-04 13:48:32.084 [A] старт pid=81312 run=nofence FENCING=0 zk=localhost:2181,localhost:2182,localhost:2183  (t=1793789312.085)
2026-11-04 13:48:32.097 [A] подключён к ZooKeeper (CONNECTED)  (t=1793789312.097)
2026-11-04 13:48:32.127 [A] зарегистрировался в выборах: /hw4/nofence/election/n_0000000000, session=0x2000d76a5700001, timeout=10s  (t=1793789312.127)
2026-11-04 13:48:32.134 [A] СТАЛ ЛИДЕРОМ, эпоха 1 (версия узла epoch 1), ожидал 0.01s  (t=1793789312.135)
2026-11-04 13:48:32.188 [A] объект clean/vacancies.jsonl: 100,922,060 байт, 25 чанков, в чекпоинте уже 0  (t=1793789312.188)
2026-11-04 13:48:32.562 [A] чанк 1/25 обработан: lines=9490 variant=988 -> чекпоинт chunk_0000 (0.37s)  (t=1793789312.562)
2026-11-04 13:48:33.844 [A] чанк 2/25 обработан: lines=9572 variant=910 -> чекпоинт chunk_0001 (0.27s)  (t=1793789313.844)
2026-11-04 13:48:35.088 [A] чанк 3/25 обработан: lines=9684 variant=859 -> чекпоинт chunk_0002 (0.24s)  (t=1793789315.089)
2026-11-04 13:48:36.291 [A] чанк 4/25 обработан: lines=9636 variant=931 -> чекпоинт chunk_0003 (0.20s)  (t=1793789316.292)
2026-11-04 13:48:37.585 [A] чанк 5/25 обработан: lines=9401 variant=982 -> чекпоинт chunk_0004 (0.26s)  (t=1793789317.585)
2026-11-04 13:48:38.780 [A] чанк 6/25 обработан: lines=9382 variant=937 -> чекпоинт chunk_0005 (0.19s)  (t=1793789318.780)
2026-11-04 13:48:39.997 [A] чанк 7/25 обработан: lines=9547 variant=938 -> чекпоинт chunk_0006 (0.20s)  (t=1793789319.998)
2026-11-04 13:48:41.236 [A] чанк 8/25 обработан: lines=9511 variant=910 -> чекпоинт chunk_0007 (0.23s)  (t=1793789321.237)
```

Рис. 10. Журнал A: 8 чанков до kill -STOP в 13:48:41 (строки выше — хвост предыдущего прогона).

```
Last login: Wed Nov  4 13:45:09 on ttys013
 ~/Documents/university/инженерия данных/hw4 > main
❯ .venv/bin/python src/scenario.py nofence
2026-11-04 13:48:31.848 [scenario] прогон nofence: FENCING=0, приостановка лидера после 8 чанков  (t=1793789311.848)
2026-11-04 13:48:32.467 [scenario] запущены координатор A (pid 81312, лидер) и B (pid 81315, запасной)  (t=1793789312.467)
2026-11-04 13:48:41.250 [scenario] kill -STOP 81312: лидер A приостановлен посреди расчёта  (t=1793789321.250)
2026-11-04 13:48:52.953 [scenario] B стал лидером через 11.63 s после приостановки A (тайм-аут сессии 10 s)  (t=1793789332.953)
2026-11-04 13:49:19.272 [scenario] B завершил расчёт и опубликовал результат через 37.99 s после приостановки A  (t=1793789359.273)
2026-11-04 13:49:21.257 [scenario] kill -CONT 81312: A возобновлён, был приостановлен 40.0 s  (t=1793789361.258)
Connection dropped: socket connection broken
Transition to CONNECTING
Session has expired
2026-11-04 13:49:23.844 [scenario] оба координатора завершились (A rc=0, B rc=0)  (t=1793789363.844)
2026-11-04 13:49:23.846 [scenario] итог A: записал результат: /hw4/nofence/result -> версия 2 (без проверки эпохи)  (t=1793789363.846)
2026-11-04 13:49:23.846 [scenario] итог B: записал результат: /hw4/nofence/result -> версия 1 (без проверки эпохи)  (t=1793789363.846)
2026-11-04 13:49:23.846 [scenario] ИТОГО: время смены лидера 11.63 s  (t=1793789363.847)

 ~/Documents/university/инженерия данных/hw4 > main !3
❯
```

Рис. 11. Итог сценария nofence: две строки «записал результат» (версии 2 и 1), смена лидера 11.63 с.

6. Этап 4. Приостановка лидера с защитой по эпохе (FENCING=1)

t, с	Событие
9.81	kill -STOP: лидер A приостановлен после 8 обработанных чанков
21.86	B стал лидером, эпоха 2 (через **12.04 с** после SIGSTOP)
21.86	B: 8 чанков уже в чекпоинте A — пропущены, расчёт продолжен с чанка 9
45.02	B: записал результат: /hw4/fence/result -> версия 1 (эпоха 2 проверена)
49.82	kill -CONT: A возобновлён (пауза 40.0 с); сессия A истекла (LOST), переподключение
52.16	A: все 17 оставшихся чанков в чекпоинте; ЗАПИСЬ ОТКЛОНЕНА: BadVersionError - моя эпоха 1 (версия 1), текущая эпоха 2 (версия 2)

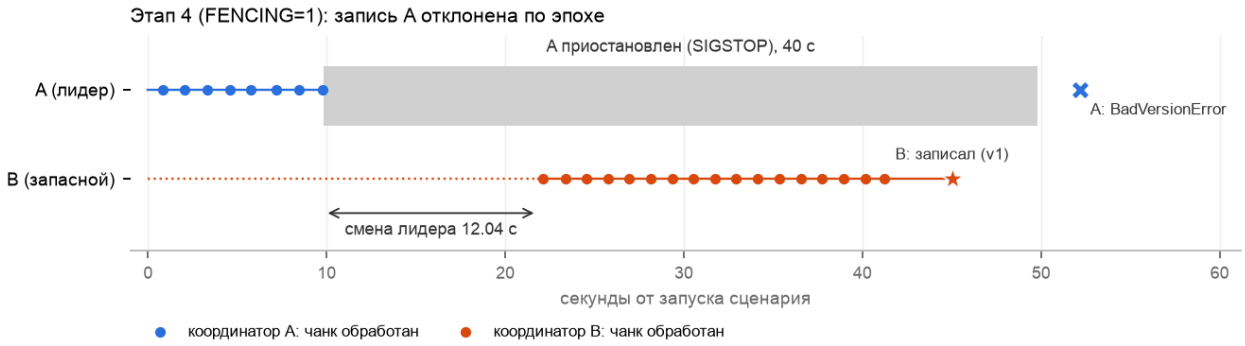


Рис. 12. Хронология прогона fence по журналам logs/fence_A.log и logs/fence_B.log.

Сценарий тот же, но публикация идёт транзакцией с проверкой версии /epoch. A пришёл с эпохой 1, а текущая — 2, поэтому транзакция отклонена с **BadVersionError**, указатель не изменился: `/hw4/fence/result` — **dataVersion = 1**, owner = B, epoch = 2. Результат один.

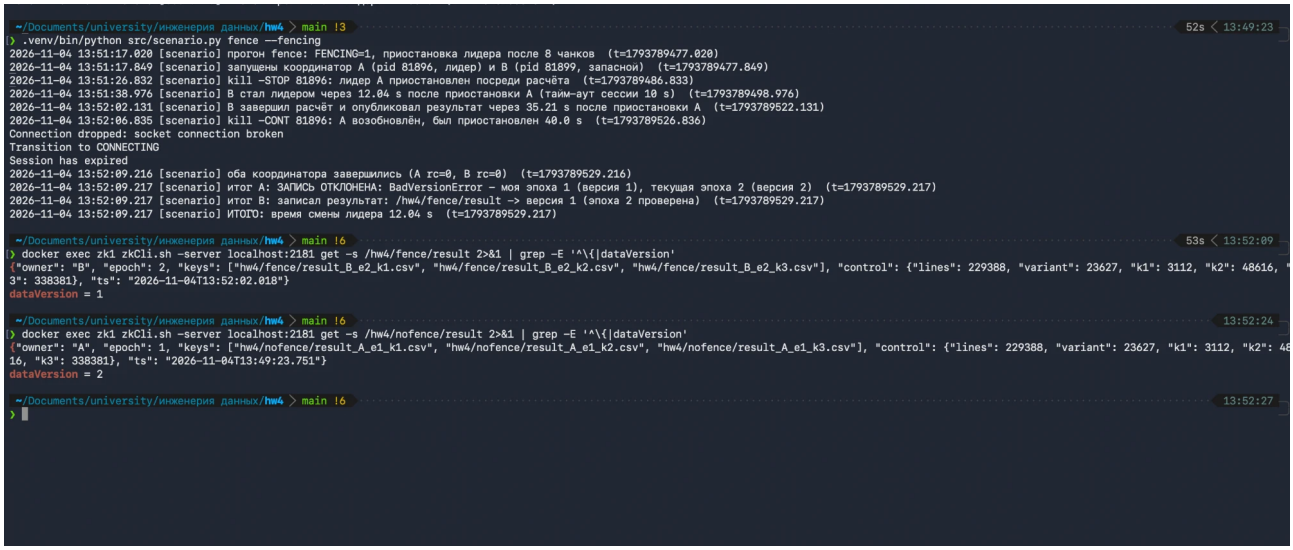


Рис. 13. Итог сценария fence (BadVersionError у A) и указатели: fence — dataVersion 1, owner B; nofence — dataVersion 2, owner A.

Вывод `zkCli get -s` для указателей и узлов epoch (outputs/zk_pointers.txt):

```
### zkCli get -s /hw4/nofence/result
{"owner": "A", "epoch": 1, "keys": ["hw4/nofence/result_A_e1_k1.csv", "hw4/nofence/result_A_e1_k2.csv", "hw4/nofence/resul...
dataVersion = 2

### zkCli get -s /hw4/nofence/epoch
2
dataVersion = 2

### zkCli get -s /hw4/fence/result
{"owner": "B", "epoch": 2, "keys": ["hw4/fence/result_B_e2_k1.csv", "hw4/fence/result_B_e2_k2.csv", "hw4/fence/result_B_e2...
dataVersion = 1

### zkCli get -s /hw4/fence/epoch
2
dataVersion = 2
```

7. Сверка результатов с ДЗ №3

Показатель	ДЗ №3	nofence A	nofence B	fence A	fence B
строк в JSONL	229 388	229 388	229 388	229 388	229 388
вакансий варианта	23 627	23 627	23 627	23 627	23 627
k=1 разных навыков	3 112	3 112	3 112	3 112	3 112
k=2 разных пар	48 616	48 616	48 616	48 616	48 616
k=3 разных троек	338 381	338 381	338 381	338 381	338 381
CSV побайтово = results/mr_k{1 2 3}.csv	—	да	да	да	да

Все четыре координатора (в том числе B, который половину чанков взял из чекпоинта A) получили те же числа, что ДЗ №3 (logs/fault_test.log, logs/verify.log в репозитории ДЗ №3). Кроме того, координатор сравнивает свои CSV с файлами `s3://hh-lake/results/mr_k{1,2,3}.csv` из ДЗ №3 байт в байт — в каждом журнале три строки «СОВПАЛО с ДЗ 3». Самая частая пара: «1с программирование | 1с: предприятие 8» — 4 465 вакансий.

8. Время смены лидера

Прогон	SIGSTOP → «СТАЛ ЛИДЕРОМ» у B	SIGSTOP → B опубликовал	Пауза A
nofence (этап 3)	**11.63 с**	37.98 с	40.0 с
fence (этап 4)	**12.04 с**	35.20 с	40.0 с

Смена лидера занимает тайм-аут сессии (10 с) плюс до двух секунд. Приостановленный A перестаёт слать heartbeat, сервер замечает истечение сессии не мгновенно, а при очередной проверке (они идут с шагом tickTime = 2 с), удаляет эфемерный узел A и отправляет B уведомление watch. Сами перевыборы и увеличение эпохи у B занимают ~15 мс («узел исчез — перевыборы» → «СТАЛ ЛИДЕРОМ»). Уменьшить время можно меньшим тайм-аутом сессии, но тогда короткая пауза GC или сети будет чаще приводить к ложной смене лидера.

9. Ответы на вопросы

Почему серверов три, а не два и не четыре?

ZooKeeper выполняет запись, только если её подтвердило большинство серверов — строго больше половины. При трёх серверах большинство — два, значит один сервер может упасть, и ансамбль продолжит работать; это и проверено на этапе 2. При двух серверах большинство — оба, поэтому падение любого из них останавливает систему: надёжность не выше, чем у одного сервера, а машин, которые могут сломаться, уже две. При четырёх большинство — три, то есть ансамбль по-прежнему переживает только один отказ, как и три сервера, но каждая запись ждёт лишнего подтверждения. Поэтому размер ансамбля выбирают нечётным: 3 сервера выдерживают 1 отказ, 5 — 2. Нечётное число ещё и исключает разбиение сети ровно пополам, когда ни одна из половин не может набрать большинство.

Почему защиту по эпохе проверяет получатель записи, а не ZooKeeper?

ZooKeeper может только констатировать, что сессия старого лидера истекла, и дать лидерство другому. Остановить сам процесс он не может и не может ему ничего сообщить, пока тот завис: в этапах 3–4 A стоял на паузе и после неё продолжил с того же места, считая себя лидером. Проверка «я ещё лидер?» перед записью не помогает: между проверкой и записью может снова случиться пауза (GC, своп, задержка сети), и ответ устареет. Надёжно только одно: писатель прикладывает к записи номер своей эпохи, а тот, кто запись принимает, в тот же момент атомарно сравнивает его с текущим и отказывает старому. Кроме того, ZooKeeper вообще не видит большинство записей — результат может уходить в S3, базу или файл. В нашей работе получатель — узел-указатель result, поэтому проверка сделана транзакцией check(epoch) + set(result) прямо в момент записи. Сами CSV в S3 при этом пишут оба координатора (под разными именами с номером эпохи), а опубликованным считается только тот, на который указывает result.

10. Замечания

• ZooKeeper запущен в Docker, а не из трёх распакованных архивов: Java на машине нет, задание допускает этот вариант. Конфигурации и dataDir при этом свои у каждого сервера, как требуется.

• Расчёт искусственно замедлен (пауза 1 с после чанка), иначе он занимает около 10 с и лидера не успеть остановить посреди работы. На результат это не влияет — сверка с ДЗ №3 побайтовая.

• Старый лидер после возобновления не пересчитывает чанки: все они уже в чекпоинте, поэтому он сразу делает reduce и пытается опубликовать результат — именно этот момент и проверяется защитой по эпохе.

• Журналы logs/ — из последних прогонов, по которым сделаны скриншоты. Текст outputs/stage2.txt получен отдельным прогоном stage2.sh, поэтому роли серверов там другие (лидер zk2), что нормально для ZooKeeper.

Репозиторий: compose.yaml, zk/zkN/conf/zoo.cfg и myid, src/ (coordinator.py, scenario.py, build_report.py), stage2.sh, журналы logs/, выводы outputs/, скриншоты report/screens/, README и этот отчёт.